

- 資料探勘作業三
 - 資料前處理
 - 1. 資料集概述
 - 2. 特徵欄位分析
 - 3. 資料集檢查
 - 3.1 缺失值
 - 3.2 資料類型
 - 4. 目標變數分佈
 - 5. 類別不平衡處理測試
 - 模型訓練流程
 - 1. 模型選用
 - 2. 參數設定
 - 2.1 預設參數 (v1)
 - 2.2 參數最佳化 (v2)
 - 2.3 閾值調整 (v3)
 - 2.4 特徵工程 + 集成式模型 (v4)
 - 2.5 機率輸出與 One-Hot Logistic Regression
 - 模型評估
 - 1. 資料未處理
 - 2. 資料平衡 (加上 `class_weight='balanced'`)
 - 3. Cross-Validation 結果
 - 4. Kaggle Score
 - 4.1 Random Forest hard label 版本
 - 4.2 更新後機率版本
 - 4.3 Probability Blend 版本
 - Kaggle Score 變化分析
 - 1. v2 改用 F1-Score 的原因
 - 2. v3 threshold tuning 的效果
 - 3. 為什麼 v4 分數大幅下降?
 - 4. 為什麼機率 submission 分數大幅提升?
 - 5. 為什麼 blend 表現最好?
 - 最佳模型
 - 結論
 - Kaggle Submission 截圖
 - 截圖 1
 - 截圖 2
 - 截圖 3

資料探勘作業三

7114056012 劉子銘

資料前處理

1. 資料集概述

項目	數值
訓練集大小	32,769 筆
測試集大小	58,921 筆
特徵數量	8 個
目標變數	ACTION (0 或 1)

2. 特徵欄位分析

欄位名稱	說明	唯一值數量	類型
RESOURCE	資源 ID	7,518	ID
MGR_ID	管理者 ID	4,243	ID
ROLE_ROLLUP_1	角色階層 1	128	ID
ROLE_ROLLUP_2	角色階層 2	177	ID
ROLE_DEPTNAME	部門名稱	449	ID
ROLE_TITLE	職稱	343	ID
ROLE_FAMILY_DESC	角色家族描述	2,358	ID
ROLE_FAMILY	角色家族	67	ID
ROLE_CODE	角色代碼	343	ID

所有特徵皆為 ID 類型，屬於高基數類別特徵。

3. 資料集檢查

3.1 缺失值

資料集	缺失值數量
訓練集	0
測試集	0

無需做缺失值處理。

3.2 資料類型

所有數值皆為數值型，不需做轉換。

4. 目標變數分佈

ACTION 值	數量	比例
1	30,872	94.21%
0	1,897	5.79%

資料存在嚴重的類別不平衡問題，比例約為 16:1，需進一步處理。

5. 類別不平衡處理測試

我們使用 Random Forest 做為模型，測試下列資料不平衡處理方法。

方法	準確率	F1-Score	AUC-ROC	Recall
基準模型（無處理）	94.87%	0.9733	0.8610	26.65%
SMOTE 過採樣	94.45%	0.9708	0.8478	35.88%
Random Undersampling	76.98%	0.8635	0.8247	72.30%
SMOTETomek	94.43%	0.9707	0.8472	38.26%
class_weight='balanced'	94.72%	0.9722	0.8628	39.84%
SMOTE + class_weight	94.45%	0.9708	0.8478	35.88%

結論: `class_weight='balanced'` 在保持高準確率與 F1-Score 的同時，顯著提升 Recall，因此選擇此方法做為處理方案。

模型訓練流程

1. 模型選用

我們先測試了幾種模型。

模型	準確率
Random Forest	94.72%
Gradient Boosting	94.19%
Logistic Regression	94.22%
Decision Tree	92.74%

最終先選擇 Random Forest 做為主要訓練模型，後續再加入 One-Hot Logistic Regression 與機率融合方法改善 Kaggle 分數。

2. 參數設定

我們將模型版本分為四類去做訓練。

2.1 預設參數（v1）

將決策樹樹量設為 100，其餘參數不做調整，用來做為 baseline 模型。

2.2 參數最佳化（v2）

使用 GridSearchCV 尋找最佳參數值。因資料不平衡，scoring 使用 F1-Score 而非 accuracy。

參數	數值
n_estimators	200
max_depth	25

參數	數值
min_samples_split	5
min_samples_leaf	1

2.3 閾值調整 (v3)

使用 v2 所得到的最佳參數，並改變模型的分類門檻。預設門檻為 0.5，但因為資料集極度不平衡，所以在驗證集中嘗試不同的閾值，以減少資料不平衡所帶來的預測偏差。

所得到最佳的閾值為 0.41。

2.4 特徵工程 + 集成式模型 (v4)

將 ID 出現的次數做計算，變成新的特徵，可以讓模型除了看到 ID 之外，也可以看到此 ID 的出現頻率。此版本集成 Random Forest、Gradient Boosting、Logistic Regression 三種模型並將其平均，使用 0.5 做為閾值做預測。

2.5 機率輸出與 One-Hot Logistic Regression

更新後發現 Kaggle 評分更適合提交 ACTION=1 的機率，而不是只提交 0/1 hard label。因此後續新增：

版本	方法
submission_best_prob	使用 Random Forest 的 <code>predict_proba</code> 輸出 ACTION=1 機率
submission_ohe_lr_prob	One-Hot Encoding 處理 ID 類別特徵，再用 Logistic Regression 輸出機率
submission_blend	將 OHE-LR 機率與 Random Forest 機率做加權融合

模型評估

我們比較了將模型進行資料平衡與未處理的結果，都是使用相同的模型。

1. 資料未處理

版本	說明	驗證集準確率	F1-Score	AUC-ROC
v1	Random Forest	94.72%	0.9723	0.8390
v2	Random Forest + GridSearchCV	94.87%	0.9733	0.8610
v3	Random Forest + threshold tuning	94.85%	0.9738	0.8610
v4	特徵工程 + 集成模型	94.19%	0.9700	0.7580

原始版本中，v3 透過 threshold tuning 取得最高的驗證集 F1-Score，v2 與 v3 的 AUC-ROC 相同，代表兩者機率排序能力接近。v4 加入特徵工程與集成模型後，驗證集指標反而下降，表示此資料集上複雜化模型不一定能提升泛化能力。

2. 資料平衡（加上 `class_weight='balanced'`）

版本	說明	驗證集準確率	F1-Score	AUC-ROC
v1_balanced	Random Forest	94.78%	0.9727	0.8448
v2_balanced	Random Forest + GridSearchCV	94.64%	0.9719	0.8606
v3_balanced	Random Forest + threshold tuning	95.03%	0.9740	0.8628
v4_balanced	特徵工程 + 集成模型	94.23%	0.9703	0.7785

balanced 版本中，v3_balanced 在驗證集 Accuracy、F1-Score 與 AUC-ROC 皆最高；但 Kaggle 分數最佳的是 v2_balanced，顯示 threshold tuning 可能對驗證集過度調整。

3. Cross-Validation 結果

版本	F1-Score
v2	0.9741
v2_balanced	0.9735

4. Kaggle Score

4.1 Random Forest hard label 版本

版本	說明	Private Score	Public Score
v1	Random Forest baseline	0.67073	0.67498
v2	GridSearchCV + scoring='f1'	0.64071	0.65635
v3	Random Forest + threshold tuning	0.60626	0.61920
v4	特徵工程 + 集成模型	0.58913	0.58772
v1_balanced	Random Forest + class_weight	0.65628	0.66703
v2_balanced	GridSearchCV + class_weight	0.67450	0.67875
v3_balanced	class_weight + threshold tuning	0.65289	0.65785
v4_balanced	特徵工程 + 集成模型 + class_weight	0.62636	0.62442

在只提交 0/1 hard label 的版本中，v2_balanced 取得最佳 Kaggle 結果。

4.2 更新後機率版本

版本	說明	Private Score	Public Score
submission_best	full-data Random Forest + class_weight, 輸出 0/1	0.68505	0.69099
submission_best_prob	full-data Random Forest + class_weight, 輸出機率	0.86584	0.86801
submission_ohe_lr_prob	One-Hot Encoding + Logistic Regression, 輸出機率	0.87610	0.88328

機率輸出明顯優於 0/1 hard label，代表 Kaggle 評分更重視排序能力，提交機率比直接提交分類結果更適合。

4.3 Probability Blend 版本

版本	融合方式	Private Score	Public Score
submission_blend_ohe90_rf10	90% OHE-LR + 10% RF	0.88187	0.88941

版本	融合方式	Private Score	Public Score
submission_blend_ohe80_rf20	80% OHE-LR + 20% RF	0.88221	0.88920
submission_blend_rank_ohe80_rf20	80% OHE-LR rank + 20% RF rank	0.88207	0.88871
submission_blend_ohe70_rf30	70% OHE-LR + 30% RF	0.88168	0.88803

最佳 Private Score 為 `submission_blend_ohe80_rf20`，最佳 Public Score 為 `submission_blend_ohe90_rf10`。

Kaggle Score 變化分析

1. v2 改用 F1-Score 的原因

原因 1：資料不平衡下 `accuracy` 容易偏向多數類別，F1-Score 更能反映分類品質。

原因 2：最佳參數與原本一致，但交叉驗證指標改為 `F1 = 0.9741`，評估目標更符合不平衡資料。

Kaggle 結果：原始 v2 分數為 Private 0.64071 / Public 0.65635；加入 `class_weight='balanced'` 的 `v2_balanced` 提升至 Private 0.67450 / Public 0.67875，顯示類別權重比單純調整 `scoring` 更有效。

2. v3 threshold tuning 的效果

關鍵因素：將預設 `threshold = 0.5` 調整為 0.41。

F1-Score 提升：v2 的 0.9733 提升至 v3 的 0.9738。

Kaggle 結果：原始 v3 下降至 Private 0.60626 / Public 0.61920；`v3_balanced` 也低於 `v2_balanced`，為 Private 0.65289 / Public 0.65785。

結論：threshold tuning 雖可提升驗證集 F1-Score，但未能改善 Kaggle 分數，推測 threshold 對驗證集過度調整，泛化效果不佳。

3. 為什麼 v4 分數大幅下降？

可能原因 1：特徵工程（ID 出現次數）可能引入雜訊。

可能原因 2：集成模型中各模型權重未優化。

可能原因 3：過擬合於驗證集，導致泛化能力下降。

結論：複雜模型不一定更好，簡單模型加上正確的資料處理更有效。

4. 為什麼機率 submission 分數大幅提升？

Kaggle 評分使用 AUC 類型指標時，模型對樣本的排序能力比最終 0/1 標籤更重要。

hard label 只保留分類結果，會失去機率排序資訊；改用 `predict_proba` 後，模型能提供更細緻的分數，因此 Random Forest 機率版從 Private 0.68505 提升到 0.86584。

One-Hot Logistic Regression 又進一步提升分數，原因是本資料集特徵主要是 ID 類別欄位，One-Hot Encoding 能更直接表示每個 ID 的影響，適合搭配 Logistic Regression 輸出穩定的機率。

5. 為什麼 blend 表現最好？

OHE-LR 與 Random Forest 學到的資訊不同。OHE-LR 對高基數 ID 類別特徵較敏感，Random Forest 則能補充部分非線性關係。將兩者機率融合後，可以保留 OHE-LR 的主要優勢，也加入 RF 的補充資訊，因此取得最高 Kaggle 分數。

最佳模型

項目	數值
最佳 Private Submission	submission_blend_ohe80_rf20
最佳 Public Submission	submission_blend_ohe90_rf10
模型組合	One-Hot Logistic Regression + Random Forest
關鍵方法	One-Hot Encoding + 機率輸出 + 加權融合
Best Private Score	0.88221

項目	數值
Best Public Score	0.88941

結論

1. 類別不平衡是關鍵問題：本資料集存在 16:1 的類別不平衡，直接影響模型在測試集上的表現。
2. class_weight 比 threshold tuning 更有效：在 Random Forest hard label 版本中，v2_balanced 是最佳 Kaggle 結果，而 threshold tuning 雖提升驗證 F1，Kaggle 分數反而下降。
3. 機率輸出比 0/1 hard label 更適合：Random Forest 改成輸出機率後，Kaggle 分數大幅提升。
4. One-Hot Logistic Regression 適合此資料集：由於特徵多為 ID 類別欄位，One-Hot Encoding 能有效表達類別資訊。
5. 融合模型取得最佳表現：OHE-LR 與 RF 機率加權融合後，最佳 Private Score 達 0.88221，最佳 Public Score 達 0.88941。

Kaggle Submission 截圖

截圖 1

 submission_v4.csv Complete (after deadline) · 4m ago	0.58913	0.58772	☐
 submission_v3.csv Complete (after deadline) · 5m ago	0.60626	0.61920	☐
 submission_v2.csv Complete (after deadline) · 5m ago	0.64071	0.65635	☐
 submission_v1.csv Complete (after deadline) · 5m ago	0.67073	0.67498	☐

截圖 2

Submission and Description		Private Score ⓘ	Public Score ⓘ	Selected
	submission_v4_balanced.csv Complete (after deadline) · 1h ago	0.62636	0.62442	☐
	submission_v3_balanced.csv Complete (after deadline) · 1h ago	0.65289	0.65785	☐
	submission_v2_balanced.csv Complete (after deadline) · 1h ago	0.67450	0.67875	☐
	submission_v1_balanced.csv Complete (after deadline) · 1h ago	0.65628	0.66703	☐

截圖 3

	submission_blend_ohe70_rf30.csv Complete (after deadline) · now	0.88168	0.88803	☐
	submission_blend_rank_ohe80_rf20.csv Complete (after deadline) · 20s ago	0.88207	0.88871	☐
	submission_blend_ohe80_rf20.csv Complete (after deadline) · 41s ago	0.88221	0.88920	☐
	submission_blend_ohe90_rf10.csv Complete (after deadline) · 2m ago	0.88187	0.88941	☐
	submission_ohe_lr_prob.csv Complete (after deadline) · 6m ago	0.87610	0.88328	☐
	submission_best_prob.csv Complete (after deadline) · 7m ago	0.86584	0.86801	☐